ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA CÔNG NGHỆ THÔNG TIN

PHÂN TÍCH VÀ ỨNG DỤNG PIXART-α TRONG BÀI TOÁN SINH ẢNH TỪ VĂN BẢN

ĐỒ ÁN CUỐI KỲ

TRÍ TUỆ NHÂN TẠO NÂNG CAO

Học viên thực hiện: **Hồ Sĩ Tuấn – 24C11032**

Trương Trung Vĩnh –25C12015

Trần Nhật Trường - 25C12014

Trương Vĩnh Hưng – 25C12023

GV phụ trách: **TS. Lê Trung Nghĩa**

TS. Bùi Duy Đăng

HỌC KỲ I – NĂM HỌC 2025-2026

MỤC LỤC

TÓM TẮT 1
I. Giới thiệu 2
1.1. Bối cảnh bài toán 2
1.2. Phân tích các nút thắt kỹ thuật hiện hữu 2
1.3. Mục tiêu nghiên cứu 3
II. Kiến thức nền tảng 3
2.1. Nguyên lý của Diffusion Model 3
2.1.1. Quá trình khuếch tán thuận (Forward Diffusion Process) 4
2.1.2. Quá trình khử nhiễu nghịch (Reverse Denoising Process) 4
2.2. Cơ chế sinh ảnh từ văn bản (Text-to-Image Mechanism) 4
2.2.1. Mã hóa ngôn ngữ chuyên sâu với Text Encoder 5
2.2.2. Tích hợp điều kiện qua cơ chế Cross-Attention 5
2.2.3. Hiệu quả tính toán trong không gian tiềm ẩn (Latent Space) 5
III. Tổng quan PixArt-α 6
3.1. Ý tưởng chính của PixArt-α 6
3.2. Đóng góp chính của PixArt-α 6
IV. Kiến trúc mô hình 8
4.1. Diffusion Transformer (DiT) 8
4.2. Cross-Attention 8
4.3. AdaLN-single 8
4.4. Re-parameterization 8
V. Chiến lược huấn luyện 9
5.1. Giai đoạn 1: Học đặc trưng ảnh 9
5.2. Giai đoạn 2: Text – Image alignment 9
5.3. Giai đoạn 3: Nâng cao chất lượng ảnh 9
VI. Cài đặt và Demo 10
6.1. Môi trường 10

6.2. Cách chạy 10
6.3. Kết quả 11
6.4. Phân tích tham số 13
VII. So sánh và đánh giá 15
7.1. So sánh với các mô hình T2I hiện đại 15
7.2. Vì sao PixArt-α hiệu quả hơn 15
7.3. Ưu điểm 16
7.4. Hạn chế 16
VIII. Kết luận và hướng phát triển 17
8.1. Kết luận 17
8.2. Hướng phát triển 17
TÀI LIỆU THAM KHẢO 18

BẢNG DANH MỤC VIẾT TẮT

Viết tắt	Thuật ngữ đầy đủ	Giải thích
AdaLN	Adaptive Layer Normalization	LayerNorm có điều kiện
AdaLN-Single	Adaptive Layer Normalization Single	Biến thể AdaLN tối giản trong PixArt-α
AI	Artificial Intelligence	Trí tuệ nhân tạo
CFG	Classifier-Free Guidance	Kỹ thuật điều khiển mức bám sát prompt
CNN	Convolutional Neural Network	Mạng nơ-ron tích chập
COCO	Common Objects in Context	Bộ dữ liệu benchmark thị giác máy tính
DiT	Diffusion Transformer	Kiến trúc Transformer cho mô hình diffusion
DPM-Solver	Diffusion Probabilistic Model Solver	Thuật toán lấy mẫu cho diffusion
FID	Fréchet Inception Distance	Chỉ số đánh giá chất lượng ảnh sinh
GPU	Graphics Processing Unit	Bộ xử lý đồ họa phục vụ tính toán song song
LAION	Large-scale Artificial Intelligence Open Network	Bộ dữ liệu ảnh–văn bản quy mô lớn
LN	Layer Normalization	Kỹ thuật chuẩn hóa theo lớp trong mạng nơ-ron
Q, K, V	Query, Key, Value	Ba thành phần của cơ chế Attention
SA-Solver	Stochastic Adams Solver	Bộ lấy mẫu tối ưu chi tiết ảnh
SOTA	State-of-the-Art	Phương pháp đạt hiệu năng tốt nhất hiện tại
T2I	Text-to-Image	Bài toán sinh ảnh từ văn bản
T5	Text-to-Text Transfer Transformer	Mô hình Transformer xử lý ngôn ngữ tự nhiên

T5-XXL	Text-to-Text Transfer Transformer XXL	Phiên bản kích thước lớn của T5
U-Net	U-Net Architecture	Kiến trúc encoder–decoder phổ biến trong diffusion
VAE	Variational Autoencoder	Mô hình mã hóa–giải mã xác suất
ViT	Vision Transformer	Transformer áp dụng cho dữ liệu hình ảnh

TÓM TẮT

Sự phát triển của các mô hình khuếch tán (Diffusion Models) đã thúc đẩy mạnh mẽ bài toán sinh ảnh từ văn bản (Text-to-Image Synthesis – T2I), cho phép tạo ra hình ảnh có chất lượng cao và tính ổn định vượt trội so với các phương pháp sinh ảnh trước đây. Tuy nhiên, các hệ thống tiên tiến hiện nay thường yêu cầu chi phí huấn luyện lớn và tài nguyên tính toán đáng kể, gây khó khăn cho việc tiếp cận và mở rộng nghiên cứu. PixArt-α được đề xuất nhằm giải quyết vấn đề này thông qua việc tối ưu hóa kiến trúc mô hình và chiến lược huấn luyện thay vì chỉ mở rộng quy mô dữ liệu hoặc phần cứng.

PixArt-α áp dụng kiến trúc Diffusion Transformer (DiT) kết hợp với cơ chế điều kiện hóa đơn giản hóa AdaLN-Single để giảm số lượng tham số và chi phí tính toán. Đồng thời, mô hình sử dụng bộ mã hóa văn bản T5-XXL nhằm cải thiện khả năng hiểu ngữ nghĩa của các câu lệnh phức tạp. Một đóng góp quan trọng khác là chiến lược huấn luyện phân giai đoạn, trong đó quá trình học được tách thành các bước riêng biệt bao gồm học đặc trưng hình ảnh, căn chỉnh văn bản–hình ảnh và tinh chỉnh chất lượng thẩm mỹ. Cách tiếp cận này giúp tăng hiệu quả hội tụ và giảm đáng kể chi phí huấn luyện trong khi vẫn duy trì chất lượng sinh ảnh cạnh tranh với các mô hình hiện đại.

Báo cáo này trình bày tổng quan kiến thức nền tảng, phân tích kiến trúc PixArt-α, quy trình huấn luyện, cũng như đánh giá thực nghiệm và so sánh với Stable Diffusion. Kết quả cho thấy việc tối ưu hóa thiết kế mô hình và dữ liệu có thể trở thành hướng phát triển hiệu quả cho các hệ thống AI tạo sinh trong tương lai.

I. Giới thiệu

1.1. Bối cảnh bài toán

Lĩnh vực Trí tuệ Nhân tạo tạo sinh (Generative AI) đang phát triển nhanh chóng, đặc biệt trong bài toán sinh ảnh từ văn bản, nơi mô hình cần chuyển đổi mô tả ngôn ngữ tự nhiên thành hình ảnh phù hợp về nội dung và ngữ nghĩa. Mục tiêu không chỉ là tạo ra hình ảnh có độ phân giải cao mà còn đảm bảo sự tương ứng giữa thông tin văn bản và đặc trưng thị giác.

Sự xuất hiện của Diffusion Models đã mang lại một hướng tiếp cận hiệu quả cho bài toán sinh dữ liệu. Các mô hình này học cách khôi phục dữ liệu gốc thông qua quá trình khử nhiễu dần từ tín hiệu nhiễu Gaussian, giúp quá trình huấn luyện ổn định và cải thiện chất lượng hình ảnh so với nhiều phương pháp trước đây như GAN.

Gần đây, xu hướng tích hợp kiến trúc Transformer vào mô hình khuếch tán (Diffusion Transformer – DiT) cho thấy khả năng học quan hệ ngữ cảnh toàn cục tốt hơn so với kiến trúc U-Net truyền thống, đặc biệt khi quy mô mô hình tăng lên. Tuy nhiên, sự gia tăng kích thước mô hình cũng kéo theo chi phí huấn luyện cao, trở thành thách thức quan trọng đối với việc phát triển các hệ thống T2I hiệu quả.

1.2. Phân tích các nút thắt kỹ thuật hiện hữu

Dù đạt được những bước tiến vượt bậc, các hệ thống T2I hiện nay vẫn tồn tại những rào cản mang tính hệ thống:

- Sự bùng nổ chi phí tài nguyên: Việc huấn luyện các mô hình SOTA (State-of-the-art) đòi hỏi hạ tầng GPU chuyên dụng và thời gian vận hành kéo dài hàng tháng, khiến các đơn vị nghiên cứu nhỏ lẻ khó lòng tiếp cận.
- Nhiễu ngữ nghĩa trong dữ liệu quy mô lớn: Các tập dữ liệu như LAION dù đồ sộ nhưng chứa đựng quá nhiều cặp ảnh-văn bản không tương quan hoặc mô tả hời hợt. Điều này buộc mô hình phải tiêu tốn nhiều chu kỳ huấn luyện chỉ để lọc bỏ "nhiễu" thay vì học các khái niệm mới.
- Sự thiếu hiệu quả về tham số trong kiến trúc DiT: Các mô hình DiT thế hệ đầu thường sử dụng các cơ chế điều kiện hóa (conditioning) cồng kềnh, gây lãng phí bộ nhớ và chậm quá trình hội tụ mà không mang lại sự gia tăng chất lượng tương xứng.

1.3. Mục tiêu nghiên cứu

Báo cáo này tập trung phân tích lộ trình giải quyết các bài toán trên thông qua phương pháp tiếp cận của PixArt-α. Thay vì chấp nhận mức chi phí mặc định, PixArt-α đề xuất một triết lý thiết kế mới: Hiệu quả thông qua tinh lọc.

Các mục tiêu phân tích chính bao gồm:

1. Kiến trúc Diffusion Transformer cải tiến: Làm rõ cách khối DiT kết hợp với các lớp tối ưu (như AdaLN-Single) để giảm thiểu áp lực tham số.
2. Chiến lược huấn luyện phân giai đoạn (Decomposition): Phân tích cách mô hình tách biệt các nhiệm vụ: học cấu trúc hình ảnh, học căn chỉnh văn bản và tinh chỉnh thẩm mỹ để tăng tốc độ hội tụ.
3. Hệ thống dữ liệu giàu thông tin: Đánh giá tầm quan trọng của việc gán nhãn lại (Re-captioning) trong việc nâng cao khả năng hiểu prompts phức tạp.
4. Đánh giá thực nghiệm so sánh: Đối chiếu PixArt-α với các dòng Stable Diffusion để khẳng định vị thế vượt trội về hiệu suất sử dụng tài nguyên.

Thông qua việc giải mã các thành phần này, báo cáo hướng tới việc khẳng định: Trong kỷ nguyên mô hình lớn, sự tối ưu về thuật toán và chất lượng dữ liệu quan trọng hơn sức mạnh tính toán thuần túy.

Để hiểu rõ hơn cách PixArt-α giải quyết các vấn đề trên, phần tiếp theo sẽ trình bày tổng quan về ý tưởng thiết kế và những đóng góp chính của mô hình trong bài toán sinh ảnh từ văn bản.

II. Kiến thức nền tảng

Để làm rõ những đột phá của PixArt-α trong việc tối ưu hóa hiệu suất, cần thiết phải xem xét hai trụ cột lý thuyết cốt lõi: mô hình khuếch tán xác suất (Diffusion Models) và cơ chế điều khiển sinh ảnh bằng ngôn ngữ (Conditional Text-to-Image Generation).

2.1. Nguyên lý của Diffusion Model

Mô hình khuếch tán (Diffusion Model) là một lớp mô hình sinh dữ liệu hoạt động dựa trên nguyên lý đảo ngược quá trình phá hủy cấu trúc bằng nhiễu ngẫu nhiên. Khác với các mô hình đối kháng (GAN), Diffusion Model không cố gắng học hàm

sinh trực tiếp mà học cách "kết tinh" dữ liệu từ trạng thái hỗn loạn thông qua một chuỗi các bước khử nhiễu.

2.1.1. Quá trình khuếch tán thuận (Forward Diffusion Process)

Trong giai đoạn này, dữ liệu gốc x_0 dần bị biến đổi thành nhiễu Gaussian thông qua một chuỗi Markov gồm T bước thời gian. Tại mỗi bước t, một lượng nhiễu nhỏ được thêm vào theo phân phối:

$$q(x_t | x_{t-1}) = N(x_t; \sqrt{1-\beta_t}x_{t-1}, \beta_t I)$$

Trong đó, β_t là hệ số điều phối lượng nhiễu (noise schedule). Khi T □ ∞, hình ảnh ban đầu sẽ mất hoàn toàn cấu trúc và trở thành nhiễu trắng thuần túy. Đáng chú ý, quá trình này là cố định và không yêu cầu tham số học, đóng vai trò tạo ra "mẫu đích" để mô hình luyện tập khả năng phục hồi thông tin.

2.1.2. Quá trình khử nhiễu nghịch (Reverse Denoising Process)

Đây là trọng tâm của quá trình học máy. Một mạng thần kinh (thường là U-Net hoặc Transformer) được huấn luyện để dự đoán lượng nhiễu đã được thêm vào tại mỗi bước t. Mục tiêu là cực tiểu hóa hàm mất mát (Loss function):

$$L = E_{x_0,\epsilon,t}[||\epsilon - \epsilon_0(x_t, t)||^2]$$

Trong đó ϵ là nhiễu thực tế và ϵ_0 là nhiễu do mô hình dự đoán. Hệ quả của quá trình này là sau khi huấn luyện, ta có thể khởi tạo một ma trận nhiễu ngẫu nhiên và thực hiện khử nhiễu lặp lại để thu được một mẫu dữ liệu mới thuộc phân phối của tập huấn luyện.

2.2. Cơ chế sinh ảnh từ văn bản (Text-to-Image Mechanism)

Sinh ảnh từ văn bản (Text-to-Image - T2I) về bản chất là một bài toán khuếch tán có điều kiện (Conditional Diffusion). Ở đây, quá trình khử nhiễu không diễn ra tự do mà được hướng dẫn bởi các đặc trưng ngữ nghĩa từ câu mô tả đầu vào.

2.2.1. Mã hóa ngôn ngữ chuyên sâu với Text Encoder

Để mô hình "hiểu" được yêu cầu của người dùng, văn bản thô cần được chuyển đổi thành các vector biểu diễn đặc trưng (Embeddings).

- Một số mô hình hiện đại sử dụng các text encoder lớn như T5 để cải thiện khả năng hiểu ngữ nghĩa.
- Ưu thế của T5 nằm ở khả năng hiểu sâu các cấu trúc ngữ pháp phức tạp và quan hệ logic dài. Điều này cực kỳ quan trọng đối với việc xử lý các prompts chi tiết (Informative Prompts), giúp mô hình nắm bắt chính xác các thuộc tính của đối tượng và bố cục không gian.

2.2.2. Tích hợp điều kiện qua cơ chế Cross-Attention

Thông tin từ văn bản được nhúng vào các lớp của mô hình khuếch tán thông qua cơ chế Cross-Attention. Tại đây, các đặc trưng của hình ảnh đóng vai trò là Query (Q), trong khi đặc trưng văn bản đóng vai trò là Key (K) và Value (V).

Thông qua phép toán Attention, mô hình tự động học cách tập trung vào các từ khóa cụ thể để hình thành các vùng pixel tương ứng (ví dụ: từ "golden retriever" sẽ kích hoạt các neuron chịu trách nhiệm về hình dáng và màu lông của chó). Đây là cơ chế then chốt giúp văn bản "điều khiển" được hình ảnh.

2.2.3. Hiệu quả tính toán trong không gian tiềm ẩn (Latent Space)

Trong các hệ thống sinh ảnh hiện đại, việc thực hiện khuếch tán trực tiếp trên không gian điểm ảnh (pixel space) thường đòi hỏi chi phí tính toán và bộ nhớ rất lớn do số chiều dữ liệu cao. Để khắc phục hạn chế này, nhiều mô hình khuếch tán áp dụng phương pháp làm việc trong không gian tiềm ẩn (latent space).

Cụ thể, một mô hình Variational Autoencoder (VAE) được sử dụng để nén hình ảnh gốc thành một biểu diễn có kích thước nhỏ hơn nhưng vẫn giữ lại các đặc trưng ngữ nghĩa quan trọng. Quá trình khuếch tán và khử nhiễu sau đó được thực hiện trên biểu diễn nén này thay vì trực tiếp trên ảnh gốc. Cuối cùng, bộ giải mã (decoder) của VAE sẽ chuyển biểu diễn latent đã được khử nhiễu trở lại thành hình ảnh hoàn chỉnh.

Cách tiếp cận này giúp giảm đáng kể chi phí tính toán, tăng tốc độ huấn luyện và suy luận, đồng thời vẫn duy trì chất lượng hình ảnh cao. Đây cũng là nền tảng quan trọng cho các mô hình sinh ảnh quy mô lớn trong các hệ thống Text-to-Image hiện nay

III. Tổng quan PixArt-α

Sau khi đã trình bày các kiến thức nền tảng về mô hình khuếch tán và cơ chế sinh ảnh từ văn bản, phần này giới thiệu tổng quan về PixArt-α — một mô hình Text-to-Image hiện đại được thiết kế nhằm cải thiện hiệu quả huấn luyện và giảm chi phí tính toán trong khi vẫn duy trì chất lượng hình ảnh ở mức cao.

3.1. Ý tưởng chính của PixArt-α

Sự phát triển của các mô hình sinh ảnh từ văn bản dựa trên diffusion trong những năm gần đây đã đạt được những bước tiến lớn về chất lượng hình ảnh. Tuy nhiên, phần lớn các hệ thống này phụ thuộc vào quy mô dữ liệu cực lớn và tài nguyên tính toán đắt đỏ, khiến chi phí huấn luyện trở thành rào cản quan trọng đối với việc nghiên cứu và triển khai thực tế.

PixArt-α được đề xuất với một triết lý thiết kế khác biệt: hiệu năng cao không nhất thiết phải đạt được thông qua việc mở rộng quy mô mô hình hoặc dữ liệu, mà có thể đạt được bằng cách tối ưu hóa toàn diện pipeline huấn luyện.

Thay vì tập trung vào một thành phần riêng lẻ, PixArt-α xem toàn bộ hệ thống sinh ảnh như một chuỗi xử lý thống nhất, trong đó hiệu quả tổng thể phụ thuộc vào sự phối hợp giữa kiến trúc mô hình, cơ chế liên kết văn bản–hình ảnh và chiến lược huấn luyện. Từ góc nhìn này, mô hình hướng tới ba mục tiêu chính:

- Cải thiện khả năng biểu diễn để mô hình nắm bắt tốt hơn quan hệ toàn cục trong ảnh;
- Tăng cường mức độ hiểu ngữ nghĩa của mô tả văn bản, đặc biệt với các prompt dài và phức tạp;
  Giảm chi phí huấn luyện thông qua quy trình học có cấu trúc thay vì huấn luyện toàn bộ hệ thống ngay từ đầu.

Cách tiếp cận này giúp PixArt-α chuyển trọng tâm từ “scale-up” sang “optimize-the-pipeline”, mở ra hướng phát triển hiệu quả chi phí cho các hệ thống Text-to-Image thế hệ mới.

3.2. Đóng góp chính của PixArt-α

Dựa trên triết lý tối ưu hóa pipeline tổng thể, PixArt-α giới thiệu ba cải tiến kỹ thuật quan trọng trong kiến trúc và quy trình huấn luyện mô hình diffusion.

Chuyển đổi sang Diffusion Transformer (DiT)

Khác với nhiều mô hình diffusion trước đây sử dụng kiến trúc U-Net dựa trên CNN, PixArt-α áp dụng Diffusion Transformer (DiT) cho quá trình khử nhiễu. Kiến trúc

Transformer cho phép mô hình khai thác cơ chế self-attention toàn cục, từ đó học được các quan hệ không gian và ngữ nghĩa phức tạp giữa các vùng khác nhau của hình ảnh.

Nhờ khả năng mô hình hóa phụ thuộc dài hạn, DiT giúp cải thiện tính nhất quán tổng thể của ảnh sinh ra, đặc biệt trong các cảnh có nhiều đối tượng hoặc cấu trúc phức tạp.

Tối ưu hóa cơ chế điều kiện hóa văn bản

PixArt-α sử dụng bộ mã hóa ngôn ngữ mạnh dựa trên T5 để biểu diễn thông tin văn bản trước khi đưa vào mô hình diffusion. Biểu diễn ngôn ngữ chất lượng cao giúp tăng cường sự liên kết giữa đặc trưng văn bản và đặc trưng hình ảnh thông qua cơ chế attention.

Nhờ đó, mô hình có khả năng bám sát nội dung prompt tốt hơn, giảm hiện tượng sai lệch ngữ nghĩa và cải thiện chất lượng sinh ảnh đối với các mô tả dài hoặc chứa nhiều thuộc tính chi tiết.

Chiến lược huấn luyện phân giai đoạn hiệu quả chi phí

Một đóng góp quan trọng của PixArt-α là chiến lược huấn luyện phân giai đoạn (progressive training). Thay vì huấn luyện toàn bộ hệ thống trên dữ liệu quy mô lớn ngay từ đầu, quá trình học được chia thành các bước tuần tự:

1. Học cấu trúc hình ảnh cơ bản;
2. Học liên kết giữa văn bản và hình ảnh;
3. Tinh chỉnh chất lượng và độ thẩm mỹ của ảnh sinh ra.

Cách tiếp cận "chia để trị" này giúp giảm đáng kể chi phí tính toán và thời gian huấn luyện, đồng thời vẫn đạt hiệu năng cạnh tranh với các mô hình sinh ảnh quy mô lớn.

Từ các đóng góp trên, PixArt-α cho thấy rằng việc thiết kế lại pipeline huấn luyện một cách có hệ thống có thể mang lại hiệu quả tương đương - hoặc thậm chí vượt trội - so với việc chỉ mở rộng quy mô dữ liệu và mô hình. Phần tiếp theo sẽ trình bày chi tiết kiến trúc PixArt-α nhằm làm rõ cách các thành phần này được tích hợp trong thực tế.

IV. Kiến trúc mô hình

4.1. Diffusion Transformer (DiT)

U-Net là một cấu trúc được sử dụng rộng rãi cho quá trình encoder-decoder hình ảnh, trong bài toán hiện tại là quá trình khử nhiễu ra khỏi hình ảnh, mặc dù các lớp CNN đã và đang được ứng dụng nhiều trong các bài toán về hình ảnh, tuy vậy chúng lại khó khăn trong việc mở rộng kích cỡ ảnh cũng như học các mối quan hệ toàn cục trong hình ảnh. Mô hình phân lớp Vision Transformer (ViT) đã chứng minh được tính hiệu quả của mô hình Transformer trong tác vụ phân lớp hình ảnh cũng như tạo sinh hình ảnh. Bên cạnh đó, việc xử lý hình ảnh thành các patch embeddings cũng góp phần đơn giản hóa tác vụ mở rộng độ phân giải của ảnh. Mô hình DiT thay thế kiến trúc U-Net bằng kiến trúc ViT để tận dụng các điểm mạnh nằm trên cũng như để dễ dàng tích hợp với mô hình ngôn ngữ để có thể sinh ảnh khớp với ngữ cảnh của prompt.

4.2. Cross-Attention

Cross-Attention là một cấu trúc quan trọng trong việc tạo sinh hình ảnh theo ngữ ảnh được cho trước, với khả năng của các lớp transformer, việc áp dụng cross-attention giúp mô hình đạt được tính đúng về ngữ cảnh ở mức toàn cục. Từ đó mà mô hình có thể bám sát với prompt của người dùng. Ở mô hình đề xuất, tác giả sử dụng multi-head cross-attention ở giữa lớp self-attention và feedforward nhằm mục đích cho mô hình điều chỉnh thông tin hình ảnh sinh ra được phù hợp ngữ cảnh mà text-embedding cung cấp đang hướng tới.

4.3. AdaLN-single

AdaLN dùng để nhúng các thông tin về phân lớp cũng như timestep hiện tại của ảnh. Tuy vậy, tác giả nhận thấy rằng chỉ có tham số về timestep có tác động đến bài toàn text-to-image, do đó đề xuất áp dụng adaLN-single. Với adaLN-single, mô hình chỉ nhúng thông tin về timestep ở block transformer đầu tiên, nhờ đó mô hình giảm được một lượng lớn tham số mà vẫn giữ được ngữ cảnh nhờ có lớp cross-attention đã tích hợp ở trên.

4.4. Re-parameterization

AdaLN-single đã loại bỏ phân lớp ra khỏi thông tin nhúng cho nên để có thể tận dụng lại mô hình pre-train trước đó, tác giả đã bổ sung thêm các lớp nhúng có thể học được tại các block transformer sau block transformer đầu tiên, với mục đích có thể tái tạo lại trực tiếp các tham số shifts và scales của các block transformer thông qua tham số shifts và scales tại block transformer đầu tiên, từ đó mà mô hình vẫn có thể tận dụng được các tham số đã pre-train đó của mô hình.

V. Chiến lược huấn luyện

5.1. Giai đoạn 1: Học đặc trưng ảnh

Mục tiêu tạo ra một cấu trúc ViT đã học được phân phối của ảnh tự nhiên, đảm bảo ảnh được sinh ra có cấu trúc hợp lý theo phân lớp được cung cấp. Ở giai đoạn này mô hình được huấn luyện trên các tệp dữ liệu phổ biến, có thể áp dụng các tham số mô hình đã train sẵn như ImageNet-pretrained để giảm thời gian huấn luyện.

5.2. Giai đoạn 2: Text – Image alignment

Với mô hình sau khi hoàn tất từ giai đoạn 1, tiến hành chuyển hướng mô hình có thể tạo sinh từ văn bản thay vì phân lớp. Giai đoạn này được tiến hành bằng cách:

- Thêm lớp cross-attention vào các DiT block để mô hình có thể hiểu và phản ánh nội dung mô tả bằng hình ảnh một cách chính xác hơn.
- Áp dụng adaLN-single giảm thiểu tham số cần phải học cho mô hình, tiết kiệm tài nguyên tính toán mà vẫn duy trì hiệu quả học.
- Áp dụng Re-parameterization để đảm bảo rằng các tham số đã học từ giai đoạn 1 vẫn giữ nguyên ý nghĩa sau khi tích hợp adaLN-single, tránh việc mất mát thông tin quan trọng.
- Tăng cường thông tin văn bản của ảnh trong dữ liệu huấn luyện bằng cách sử dụng mô hình ngôn ngữ (ở đây là T5) nhằm giúp mô hình thu nhận được nhiều thông tin hơn qua mỗi lần học qua dữ liệu.

Nhờ đã được học đặc trưng hình ảnh từ giai đoạn 1 và áp dụng các kiến trúc đề xuất cũng như bổ sung dữ liệu mang tính ngữ nghĩa cao, mô hình có thể học cách tạo sinh hình ảnh từ văn bản với chi phí huấn luyện thấp hơn.

5.3. Giai đoạn 3: Nâng cao chất lượng ảnh

Trong giai đoạn này, quá trình huấn luyện tập trung vào việc tối ưu hóa tính thẩm mỹ và khả năng kiểm soát kích thước của ảnh sinh ra. Mô hình được fine-tune với bộ dữ liệu có độ phân giải cao nhằm đảm bảo rằng các chi tiết nhỏ trong ảnh được tái hiện rõ ràng và sắc nét hơn. Việc sử dụng dữ liệu chất lượng cao không chỉ giúp cải thiện độ trung thực của hình ảnh mà còn tạo điều kiện để mô hình học được những đặc trưng tinh vi về màu sắc, ánh sáng và bố cục.

Nhờ vào cấu trúc DiT cùng với nền tảng kiến thức đã tích lũy từ hai giai đoạn trước, mô hình có khả năng rút ngắn đáng kể thời gian tinh chỉnh. Điều này đồng nghĩa với việc quá trình fine-tune trở nên hiệu quả hơn, giảm thiểu chi phí tính toán nhưng vẫn duy trì được chất lượng đầu ra. Bên cạnh đó, sự kết hợp giữa kiến trúc

DiT và dữ liệu độ phân giải cao còn giúp mô hình đạt được sự cân bằng giữa tốc độ sinh ảnh và độ chính xác về mặt thẩm mỹ.

VI. Cài đặt và Demo

6.1. Môi trường

Phần cứng:

- GPU:
  - NVIDIA GeForce (Pascal trở lên, hỗ trợ CUDA).
  - VRAM:
    - ~24GB (để chạy demo gốc từ repository)
    - ~8–12GB (khi sử dụng phiên bản tối ưu qua Diffusers)
- RAM: Tối thiểu 16GB.
- Lưu trữ: Trống ít nhất 30GB trên ổ đĩa (khuyến nghị sử dụng SSD).

Phần mềm và thư viện:

- Ngôn ngữ: Python >= 3.9.
- Thư viện chính:
  - PyTorch >= 1.13 (khuyến nghị 2.x, hỗ trợ CUDA 11.7+)
  - Gradio
  - Diffusers

6.2. Cách chạy

- Sao chép mã nguồn từ GitHub:

  git clone https://github.com/PixArt-alpha/PixArt-alpha.git

  cd PixArt-alpha

- Khởi tạo môi trường ảo (để tránh xung đột với các thư viện hệ thống):

  python -m venv venv

  .\venv\Scripts\activate

- Cài đặt các thư viện phụ thuộc (dependencies):

pip install -r requirements.txt

- Cấu hình tối ưu hệ thống (optional):
-
    - Điều hướng lưu trữ trong trường hợp ổ C:\ không đủ dung lượng.
    - Cấu hình Pagefile (trên Windows) để hỗ trợ RAM vật lý khi nạp các file trọng số lớn.
    - Và các chỉnh sửa khác cho phù hợp với cấu hình máy.
- Chạy ứng dụng demo, chạy lệnh python app/app.py
- Sau khi thông báo "Running on local URL: http://0.0.0.0:15432" xuất hiện, truy cập vào địa chỉ "http://127.0.0.1:15432" trên trình duyệt để mở giao diện tạo ảnh.

6.3. Kết quả

- Giao diện demo được dựng bằng Gradio, gồm các thành phần:
    - Prompt input: Nơi nhập câu prompt để sinh ảnh (tiếng Anh).
    - Output section: Nơi hiển thị hình ảnh được sinh ra từ prompt input.
    - Advanced options: Gồm các slider điều chỉnh kích thước (Width/Height), số bước khử nhiễu (Steps), và các bộ lấy mẫu (Samplers).
    - Examples: Các prompt mẫu được cung cấp sẵn.
- Một số kết quả được sinh ra với các options khác nhau:
    - Prompt: "A small cactus with a happy face in the Sahara desert."
        - Options: DPM-Solver, No Style, Seed = 303852902, Width = Height = 512, DPM-Solver Guidance Scale = 4.5, DPM-Solver, Inference Steps = 14, SA-Solver Guidance Scale = 3, SA-Solver Inference Steps = 25



- Options: DPM-Solver, Style Fantasy Art, Seed = 303852902, Width = Height = 512, DPM-Solver Guidance Scale = 5.5, DPM-Solver, Inference Steps = 18, SA-Solver Guidance Scale = 3, SA-Solver Inference Steps = 25



- Prompt: “A cinematic portrait of a fluffy orange cat wearing high-tech cyberpunk samurai armor, glowing blue neon lights on the suit, standing in a rainy Tokyo street at night, reflection of neon signs on puddles, hyper-realistic, 8k resolution, highly detailed fur, masterpiece.”.
  - Options: DPM-Solver, Style Manga, Seed = 303852902, Width = Height = 512, DPM-Solver Guidance Scale = 5.5, DPM-Solver, Inference Steps = 18, SA-Solver Guidance Scale = 3, SA-Solver Inference Steps = 25



- Options: DPM-Solver, Style Fantasy Art, Seed = 303852902, Width = Height = 512, DPM-Solver Guidance Scale = 5, DPM-Solver, Inference Steps = 20, SA-Solver Guidance Scale = 3, SA-Solver Inference Steps = 25



6.4. Phân tích tham số

Các tham số này điều phối cách thức mô hình toán học chuyển đổi từ dữ liệu nhiễu (noise) thành hình ảnh có ý nghĩa:

- Sampler Schedule: Thuật toán điều khiển quá trình khử nhiễu
  - DPM-Solver: Là một bộ giải toán học hiện đại được thiết kế để hội tụ nhanh. Nó dự đoán hướng đi của các điểm ảnh một cách thông minh, giúp tạo ra ảnh chất lượng cao chỉ với số bước tính toán rất ít.
  - SA-Solver: Một thuật toán lấy mẫu thay thế, tập trung vào việc duy trì độ chính xác cao hơn ở các chi tiết cực nhỏ, nhưng đổi lại tốc độ xử lý chậm hơn và cần nhiều bước hơn để hoàn thiện ảnh.
- Image Style: tham số định hướng phong cách hình ảnh đầu ra

    - Hệ thống sẽ tự động bổ sung các từ khóa mô tả phong cách (cinematic, anime, digital art,…) dựa vào style đã chọn.
    - Đồng thời, mỗi style còn đi kèm một danh sách "negative prompt" nhằm loại bỏ các đặc điểm không mong muốn như mờ, méo, hoặc không đúng phong cách.
    - Nhờ đó, người dùng có thể nhanh chóng tạo ra hình ảnh theo nhiều phong cách khác nhau mà không cần tự viết prompt phức tạp.
- Negative Prompt:
    - Danh sách các từ khóa mà mô hình cần tránh khi tạo ảnh (blurry, ugly, distorted,…).
    - Giúp cải thiện chất lượng ảnh bằng cách giảm thiểu các lỗi phổ biến trong quá trình sinh ảnh.
- Seed:
    - Quyết định trạng thái nhiễu ban đầu của mô hình. Với cùng một seed và cùng tham số, kết quả sinh ra sẽ giống nhau hoàn toàn.
    - Nếu thay đổi seed, mô hình sẽ bắt đầu từ một nhiễu khác, dẫn đến hình ảnh khác nhau dù prompt không đổi.
- Randomize Seed:
    - Khi bật, hệ thống sẽ tự động chọn seed mới cho mỗi lần chạy, giúp tạo ra các kết quả đa dạng.
    - Khi tắt, seed sẽ được giữ cố định, đảm bảo tính nhất quán giữa các lần chạy.
- Width và Height:
    - Xác định độ phân giải của ảnh được tạo ra.
    - Kích thước lớn hơn thường giúp ảnh sắc nét và chi tiết hơn, nhưng đồng thời tiêu tốn nhiều tài nguyên GPU và thời gian xử lý hơn.
- Guidance Scale:
    - Là tham số quan trọng trong kỹ thuật Classifier-Free Guidance, giúp cân bằng giữa tính sáng tạo và độ chính xác theo mô tả.
    - Nếu đặt thấp (ví dụ: 3.0), mô hình sẽ tạo ảnh tự nhiên và đa dạng hơn, nhưng có thể không bám sát prompt.
    - Nếu đặt cao (ví dụ: 9.0), mô hình sẽ cố gắng bám sát từng chi tiết trong prompt, tuy nhiên có thể khiến ảnh trở nên cứng, màu sắc gắt hoặc thiếu tự nhiên.
- Inference Steps:
    - Đây là số lần mô hình thực hiện việc chuyển đổi từ nhiễu sang ảnh.

- Số bước càng cao thì ảnh càng được tinh chỉnh kỹ hơn, dẫn đến chất lượng tốt hơn. Tuy nhiên, thời gian xử lý cũng sẽ tăng đáng kể.

VII. So sánh và đánh giá

7.1. So sánh với các mô hình T2I hiện đại

So với các mô hình phổ biến như Stable Diffusion, PixArt-α cho thấy sự khác biệt rõ rệt về cả chi phí huấn luyện lẫn hiệu quả sinh ảnh:

- Về tài nguyên huấn luyện, PixArt-α chỉ sử dụng khoảng 1.25% dữ liệu và 12% thời gian huấn luyện so với Stable Diffusion v1.5. Cụ thể, mô hình PixArt-α được huấn luyện với khoảng 25 triệu ảnh, thay vì hàng tỷ ảnh như Stable Diffusion. Chi phí huấn luyện chỉ vào khoảng 28,400 USD, thấp hơn rất nhiều so với các mô hình lớn như RAPHAEL hay các hệ thống diffusion quy mô lớn khác.
- Về chất lượng sinh ảnh, PixArt-α đạt FID xấp xỉ 7.32 trên tập COCO trong chế độ Zero-Shot, cho thấy chất lượng gần tương đương với các mô hình state-of-the-art (Imagen, RAPHAEL,…) dù sử dụng ít tài nguyên hơn đáng kể. Ngoài ra, các thí nghiệm người dùng cũng cho thấy PixArt-α được đánh giá cao hơn về cả chất lượng hình ảnh và độ phù hợp giữa ảnh và mô tả văn bản.
- Về khả năng hiểu ngữ nghĩa, PixArt-α thể hiện hiệu năng vượt trội trên các benchmark như T2I-CompBench, đặc biệt ở các tác vụ liên quan đến quan hệ đối tượng và cấu trúc phức tạp. Cho thấy PixArt-α có khả năng xử lý các yếu tố ngữ nghĩa và hình ảnh một cách chính xác và hiệu quả hơn các mô hình khác.

7.2. Vì sao PixArt-α hiệu quả hơn

Hiệu quả của PixArt-α đến từ việc tối ưu đồng thời ba thành phần chính trong pipeline huấn luyện:

- Đầu tiên, mô hình áp dụng chiến lược huấn luyện phân giai đoạn, tách bài toán text-to-image thành ba bước: học phân phối ảnh, học alignment giữa text và image, và nâng cao chất lượng thẩm mỹ. Cách tiếp cận này giúp giảm độ phức tạp của quá trình học và tăng tốc hội tụ.

- Thứ hai, PixArt-α sử dụng Diffusion Transformer (DiT) với cơ chế cross-attention để tích hợp thông tin văn bản, đồng thời áp dụng kỹ thuật re-parameterization để tận dụng trọng số từ mô hình class-conditional đã huấn luyện trước. Điều này giúp giảm đáng kể chi phí học từ đầu.
- Cuối cùng, mô hình sử dụng dữ liệu có mật độ thông tin cao, được tạo ra thông qua pipeline auto-labeling. Việc cải thiện chất lượng caption giúp giảm hiện tượng lệch giữa text và image, từ đó tăng hiệu quả huấn luyện và chất lượng alignment.

7.3. Ưu điểm

- Giảm mạnh chi phí GPU, thời gian huấn luyện và lượng dữ liệu cần thiết nhưng vẫn đạt hiệu năng cạnh tranh.
- Chất lượng hình ảnh và mức độ phù hợp với văn bản cao (kết luận từ kết quả thực nghiệm và đánh giá người dùng).
- Đạt kết quả tốt trên nhiều tiêu chí đánh giá liên quan đến ngữ nghĩa và cấu trúc hình ảnh.
- Việc tách bài toán thành nhiều giai đoạn giúp quá trình huấn luyện ổn định và hiệu quả hơn.

7.4. Hạn chế

- Mô hình gặp khó khăn trong các trường hợp yêu cầu đếm chính xác số lượng đối tượng hoặc biểu diễn chi tiết cấu trúc cơ thể người (chẳng hạn như chi tiết bàn tay), dẫn đến kết quả chưa chính xác trong một số tình huống.
- Việc sinh chữ trong ảnh vẫn còn gặp nhiều khó khăn do thiếu dữ liệu về font/letter trong training set.
- Dù đạt hiệu năng tốt với chi phí thấp, tuy nhiên PixArt-α vẫn chưa vượt trội hoàn toàn về các chỉ số như FID so với những mô hình sử dụng tài nguyên lớn hơn.
- Hiệu năng của mô hình có thể bị ảnh hưởng nếu chất lượng của dữ liệu đầu vào không đảm bảo.

VIII. Kết luận và hướng phát triển

8.1. Kết luận

PixArt-α là một mô hình sinh ảnh từ văn bản dựa trên diffusion và Transformer, được thiết kế với mục tiêu giảm chi phí huấn luyện trong khi vẫn duy trì chất lượng sinh ảnh ở mức cao.

Thông qua ba đóng góp chính gồm chiến lược huấn luyện phân giai đoạn, kiến trúc Transformer hiệu quả và dữ liệu có mật độ thông tin cao, PixArt-α đã chứng minh rằng có thể xây dựng các hệ thống text-to-image chất lượng cao mà không cần phụ thuộc vào tài nguyên quy mô lớn.

Các kết quả thực nghiệm cho thấy mô hình đạt hiệu năng cạnh tranh với các phương pháp hiện đại, đồng thời giảm đáng kể chi phí và thời gian huấn luyện, mở ra khả năng tiếp cận rộng rãi hơn cho các cá nhân và tổ chức nhỏ.

8.2. Hướng phát triển

Trong tương lai, PixArt-α có thể được cải tiến theo một số hướng sau:

- Mở rộng quy mô mô hình: Tăng kích thước mô hình và dữ liệu huấn luyện để cải thiện thêm chất lượng sinh ảnh, như được đề cập trong paper.
- Cải thiện khả năng biểu diễn chi tiết: Khắc phục các hạn chế liên quan đến đếm đối tượng và cấu trúc hình học phức tạp.
- Tối ưu pipeline dữ liệu: Nâng cao chất lượng auto-labeling nhằm cải thiện hơn nữa độ chính xác của text-image alignment.
- Ứng dụng thực tế: Áp dụng mô hình vào các hệ thống thực tế như thiết kế đồ họa, sáng tạo nội dung và hỗ trợ nghệ sĩ số.

TÀI LIỆU THAM KHẢO

[1] Junsong Chen, J. Yu, C. Ge, et al., "PixArt-α: Fast training of diffusion transformer for photorealistic text-to-image synthesis," 2023. Available: https://arxiv.org/abs/2310.00426. [Truy cập ngày 11/03/2026].

[2] J. Ho, A. Jain, and P. Abbeel, "Denoising diffusion probabilistic models," *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020. Available: https://arxiv.org/abs/2006.11239. [Truy cập ngày 14/03/2026].

[3] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer, "High-resolution image synthesis with latent diffusion models," *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022. Available: https://arxiv.org/abs/2112.10752. [Truy cập ngày 18/03/2026].

[4] A. Vaswani et al., "Attention is all you need," *Advances in Neural Information Processing Systems (NeurIPS)*, 2017. Available: https://arxiv.org/abs/1706.03762. [Truy cập ngày 13/03/2026].

[5] W. Peebles and S. Xie, "Scalable diffusion models with transformers," *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023. Available: https://arxiv.org/abs/2212.09748. [Truy cập ngày 17/03/2026].

[6] C. Raffel et al., "Exploring the limits of transfer learning with a unified text-to-text transformer," *Journal of Machine Learning Research (JMLR)*, vol. 21, no. 140, pp. 1–67, 2020. Available: https://arxiv.org/abs/1910.10683. [Truy cập ngày 11/03/2026].